Segmentação de Usuários de uma Plataforma de Streaming

Emanuel Franklin Passos Simões - 23.2.4009

Introdução

A análise de agrupamentos são técnicas aplicadas com o objetivo de identificar e agregar objetos, a partir de suas próprias características (Joseph et al., 2009, p. 430).

O presente trabalho consiste na realização de uma análise de agrupamentos para fazer uma análise dos usuários de uma plataforma de streaming, com o objetivo de verificar se há agrupamentos latentes na base de dados e identificá-los caso existam.

Materiais e métodos

A base de dados dados_streaming.csv possui 560 obsevações, de modo que cada observação é um usuário ativo de uma mesma plataforma de streaming. A base contém 6 variáveis, que são:

- **idade**: Idade dos usuários em anos;
- **horas_semana**: Horas médias de consumo por semana;
- **dias_ativos**: Número médio de dias ativos por semana;
- **avaliacoes**: Número médio de avaliações feitas por mês;
- **tempo_assinatura**: Tempo de assinatura em meses;
- **valor_plano**: Valor mensal do plano.

Os métodos que serão aplicados são a análise exploratória

Resultados e discussão

Este tópico apresenta a análise exploratória dos dados, a aplicação da análise de agrupamentos e uma breve discussão sobre cada etapa.

```r
## Instalação e importação de pacotes ---------------------------------------

if (!requireNamespace("pacman", quietly = TRUE)) {
  install.packages("pacman")
}

pacman::p_load(cluster, corrplot, factoextra, seriation,
               hopkins, RColorBrewer, skimr, tidyverse)
```

```r
## Importação dos dados -----------------------------------------------------
dados <- read.csv('tabelas/dados_streaming.csv')
head(dados)
```

```
  idade horas_semana dias_ativos avaliacoes tempo_assinatura valor_plano
1    30          5.6         3.0        0.7               11       26.24
2    21          5.5         2.1        0.4               14       32.61
3    28          3.4         2.2        0.3               10       29.96
4    26          8.9         2.6        1.1                8       35.26
5    23          3.5         1.8        1.1               15       36.97
6    18          3.7         2.0        1.0                4       35.50
```

Análise exploratória

O tópico abrange um resumo dos dados com breves discussões, bem como a investigação de possíveis grupos de usuários.

Visão geral

```r
skim(dados)
```

Table 1: Data summary

Name	dados

Number of rows	560
Number of columns	6
Column type frequency:	
numeric	6
Group variables	None

Variable type: numeric

skim_variable	n_missing	complete_rate	mean	sd	p0	p25	p50	p75	p100	hist
idade	0	1	30.74	7.62	18.0	25.00	30.00	35.00	62.0	
horas_semana	0	1	11.70	7.67	0.0	6.00	9.40	17.02	37.2	
dias_ativos	0	1	3.41	1.62	0.5	2.10	3.10	4.80	7.0	
avaliacoes	0	1	1.63	1.45	0.0	0.60	1.10	2.60	6.1	
tempo_assinatura	0	1	18.48	11.56	1.0	9.00	16.00	28.00	54.0	
valor_plano	0	1	43.78	13.75	25.0	34.42	38.94	47.73	80.0	

Com excessão da variável idade, que possui média dispersão (CV = 0,25), todas as outras possuem alta dispersão, segundo o critério do coeficiente de variação maior do que 30%. Isso sugere heterogeneidade entre os usuários, tanto na questão de atividade na plataforma, como também no tempo e valor da assinatura.

Já os histogramas sugerem haver diferentes perfis de usuários:

- Quanto à idade, observa-se que a maioria são jovens e adultos;
- A frequência de usuários com pouco consumo médio semanal, em horas, é maior do que a frequência do consumo moderado e alto;
- A distribuição dos dias ativos por semana é quase uniforme, com destaque para a frequência da atividade moderada ser mais alta e a frequência da atividade altíssima ser mais baixa;
- Quanto às avaliações, observa-se que a frequência é majoritariamente baixa;
- A frequência de usuários com pouco tempo de assinatura, em meses, é maior e sua distribuição decresse quase que uniformemente;
- Há muitos usuários cadastrados nos planos mais baratos e identificou-se um outro grupo, menor, composto por usuários cadastrados em planos mais caros.

Vale analisar se há grupos latentes, visto que há heterogeneidade de observações e os próprios dados sugerem divisões de grupos marginais.

Avaliação de outliers

```
dados_long <- dados %>%
  pivot_longer(cols = everything(),
               names_to = "variavel",
               values_to = "valor")


ggplot(dados_long, aes(x = variavel, y = valor, fill = variavel)) +
  geom_boxplot() +
  scale_fill_brewer(palette = "Pastel1")
```

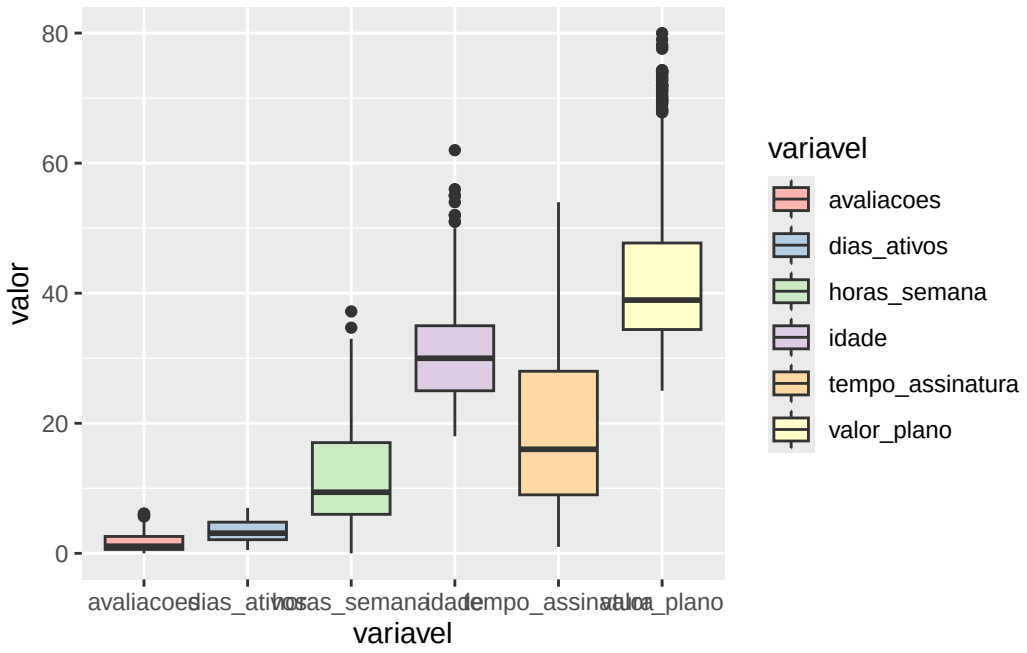

A partir do método de identificação de outliers a partir do boxplot, observou-se a presença de alguns outliers nas variáveis avaliacoes, horas_semana e valor_plano. Como verificou-se que a quantidade de outliers é bem inferior a quantidade de observações, optou-se por mantê-los.

Gráfico de cores com matriz de correlação

```
cor_mat <- dados %>%
  cor()
```

```r
corrplot(
  cor_mat,
  method = "color",
  addCoef.col = "black",
  tl.col = "black",
  tl.srt = 45
)
```

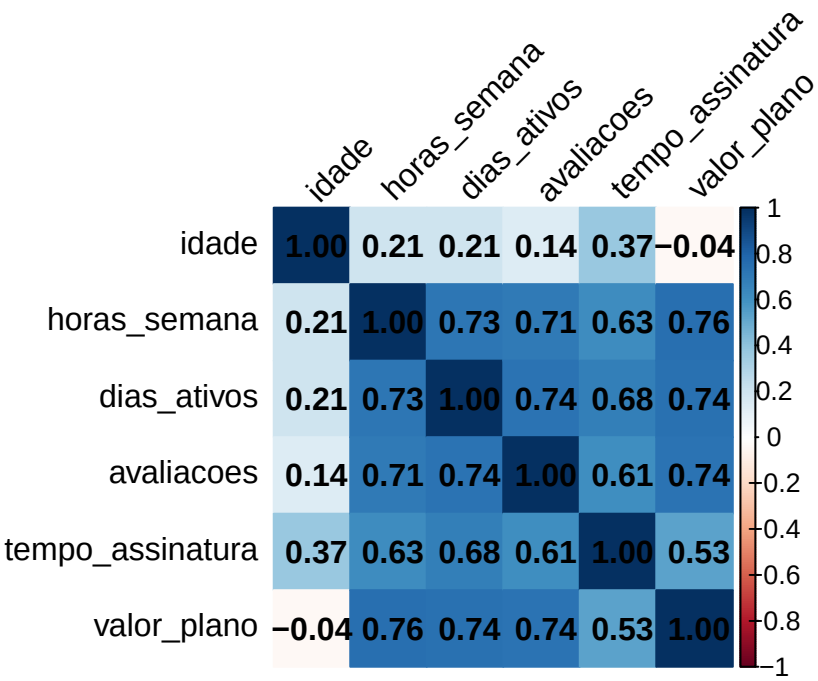

Com exceção da variável idade, todas as outras possuem correlações moderadas entre si.

Padronização dos dados

Será utilizada a análise de agrupamentos, um método sensível à escala dos dados por ser baseado na distância. Por isso, optou-se por padronizar os dados na métrica z-score. Utilizou-se a distância euclidiana por preservar a estrutura geométrica dos dados, o que dá sentido à interpretação de métodos aplicados nas próximas etapas.

```r
X <- scale(dados)

# Distância Euclidiana
D <- dist(X, method = "euclidean")
```

Avaliação da tendência de agrupamento

Estatística de Hopkins

A estatística de Hopkins avalia se os dados possuem tendência de agrupamento. Se H ~ 0.05, sugere-se aleatoriedade (sem clusters). Se H for alto, algo superior a 0.70, por exemplo, sugere-se forte estrutura de agrupamento. Como essa estatística é sensível ao tamanho amostral e ao nº de pontos amostrados, será utilizado 10% do número de pontos amostrados para a análise.

```
set.seed(12345)
m <- floor(0.1 * nrow(X))
hop <- hopkins(X, m = m)
hop
```

```
[1] 0.9984874
```

Como foi obtido um valor alto, verifica-se que há um forte indício de haver agrupamentos latentes.

Método visual (VAT)

```
VAT(D)
```

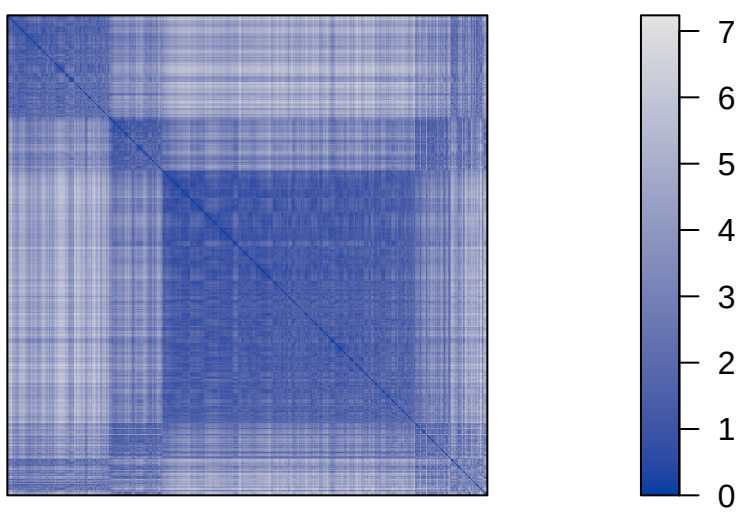

Observa-se a presença de blocos bem definidos na estrutura, separados por regiões de menor similaridade. Logo, há mais uma evidência da existência de uma estrutura de agrupamento dos dados.

PCA para visualização exploratória

```
pca <- prcomp(dados, scale. = TRUE)
pca_df <- as.data.frame(pca$x[, 1:2])
names(pca_df) <- c("PC1","PC2")

ggplot(pca_df, aes(PC1, PC2)) +
  geom_point(alpha = 0.6) +
  labs(title = "PCA (2 componentes) - visão inicial da estrutura") +
  theme_minimal()
```

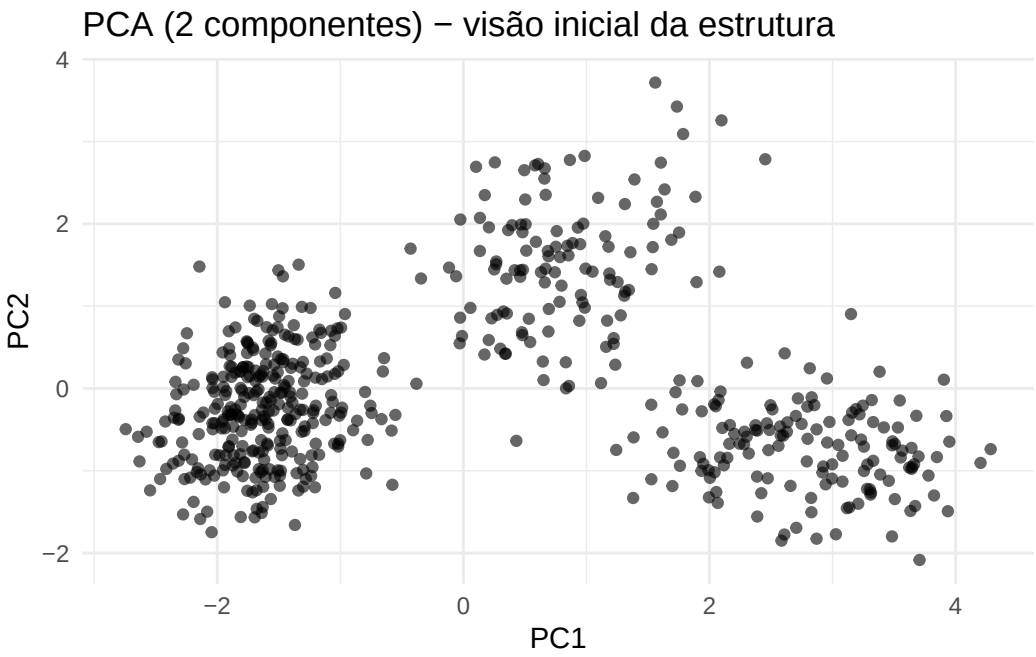

A partir da análise de componentes principais com dois componentes, percebe-se que há indícios da formação de três grupos bem definidos. Portanto, sugere-se que há uma estrutura latente que separa as observações.

Visto que há três métodos que sugerem fortemente a existência de grupos latentes, optou-se por continuar a análise e partir para os métodos hierárquicos.

Métodos hierárquicos

Correlação cofenética

Nesse procedimento foi testado os métodos single, complete, centroid, average e ward.D2 a partir do critério de correlação cofenética.

```
metodos <- c("single", "complete", "centroid", "average", "ward.D2")

hcl_list <- lapply(metodos, function(met) hclust(D, method = met))
names(hcl_list) <- metodos


# Correlação cofenética
coph_corr <- sapply(hcl_list, function(hc) {
  cor(D, cophenetic(hc))
})
coph_corr
```

```
   single  complete  centroid   average   ward.D2
0.7437501 0.8304712 0.8176564 0.8607456 0.8030811
```

```
melhor_met <- names(which.max(coph_corr))
```

O método com a maior correlação cofenética é o average, portanto será o escolhido para fazer o dendrograma, pois ele será mais fiel às distâncias.

Dendrograma e escolha do número de clusters

```
hc_best <- hcl_list[[melhor_met]]

# Visualização de alta qualidade
fviz_dend(hc_best, k = 3, # Número de grupos
          cex = 0.5, # Tamanho da label
          k_colors = c("#2E9FDF", "#ed2602", "#E7B800"),
          color_labels_by_k = TRUE, # Colorir labels
          rect = TRUE, # Adicionar retângulo
          main = "Dendrograma fviz_dend")
```

```
Warning: `aes_string()` was deprecated in ggplot2 3.0.0.
i Please use tidy evaluation idioms with `aes()`.
i See also `vignette("ggplot2-in-packages")` for more information.
i The deprecated feature was likely used in the factoextra package.
  Please report the issue at <https://github.com/kassambara/factoextra/issues>.

Warning: Using `size` aesthetic for lines was deprecated in ggplot2 3.4.0.
i Please use `linewidth` instead.
i The deprecated feature was likely used in the factoextra package.
  Please report the issue at <https://github.com/kassambara/factoextra/issues>.

Warning: The `<scale>` argument of `guides()` cannot be `FALSE`. Use "none" instead as
of ggplot2 3.3.4.
i The deprecated feature was likely used in the factoextra package.
  Please report the issue at <https://github.com/kassambara/factoextra/issues>.
```

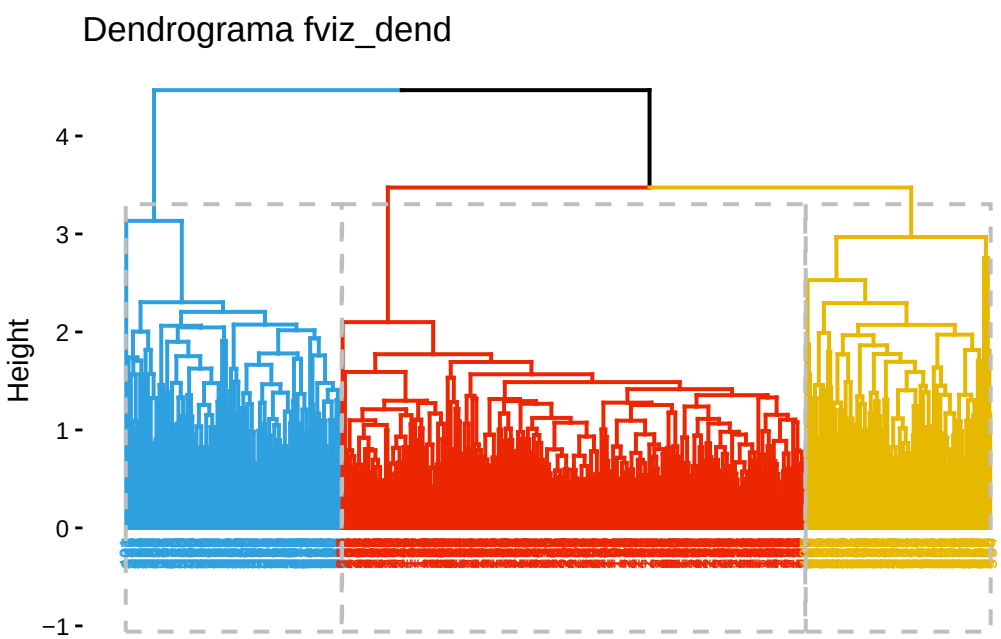


```r
cluster_hc <- cutree(hc_best, k = 3)
table(cluster_hc)
```

```
cluster_hc
  1   2   3
300 140 120
```

A partir do dendrograma, observa-se a presença de 3 agrupamentos bem definidos, de modo que há um grupo majoritário (cor vermelha) e dois grupos menores com tamanhos parecidos (cores azul e amarelo).

Validação por silhueta

```r
# Silhueta para a solução hierárquica
sil_hc <- silhouette(cluster_hc, D)

# Silhueta média global
mean_sil <- mean(sil_hc[, "sil_width"])
mean_sil
```

```
[1] 0.4764816
```

```r
fviz_silhouette(sil_hc) +
  labs(
    title = "Silhueta - Clustering hierárquico (complete, k = 3)",
    subtitle = paste("Silhueta média =", round(mean_sil, 3))
  )
```

```
  cluster size ave.sil.width
1       1  300          0.55
2       2  140          0.42
3       3  120          0.35
```

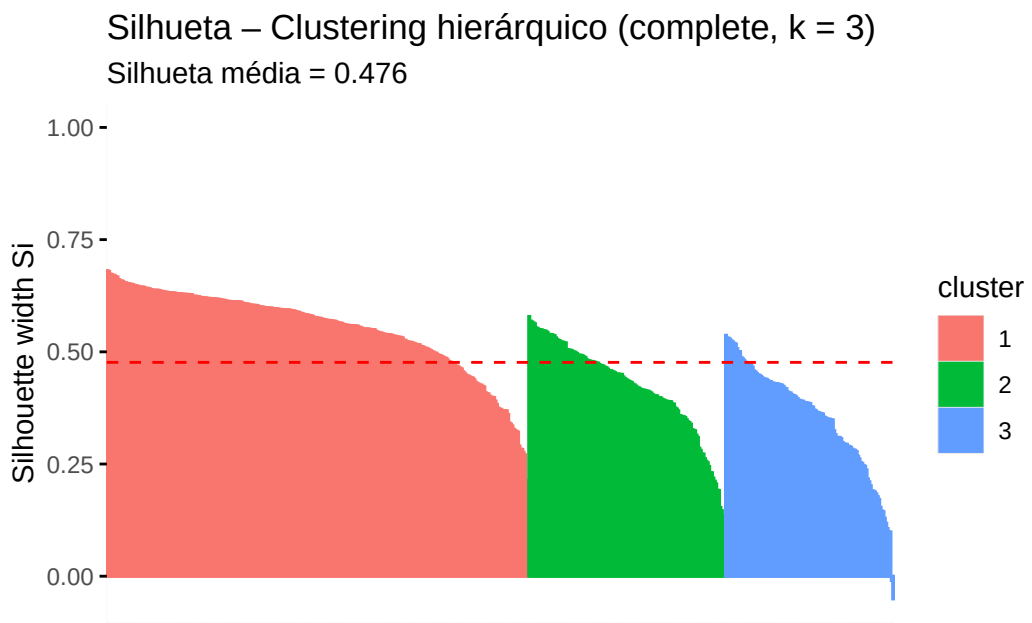


```r
sil_df <- as.data.frame(sil_hc)
sil_df$cluster <- factor(cluster_hc)

sil_df %>%
  group_by(cluster) %>%
  summarise(
    n = n(),
    sil_media = mean(sil_width),
    sil_min = min(sil_width),
    sil_max = max(sil_width)
  )
```

```
# A tibble: 3 x 5
  cluster     n sil_media sil_min sil_max
  <fct>   <int>     <dbl>   <dbl>   <dbl>
1 1         300     0.551  0.201    0.681
2 2         140     0.421  0.114    0.579
3 3         120     0.354 -0.0508   0.537
```

Para avaliar a qualidade da solução hierárquica, foi utilizado o método da silhueta, que avalia o quão bem cada observação está alocada no seu grupo. Obteve-se o valor médio de 0.47, o que indica uma alocação moderada. Percebe-se também que o grupo majoritário possui uma

silhueta média superior as demais (0.55), enquanto o grupo minoritário apresentou silhueta média inferior as demais (0.35), porém ainda é considerado uma alocação moderada.

Avaliando outros valores de k

```r
ks <- c(2, 3, 4, 5)

sil_results <- lapply(ks, function(k) {
  cl <- cutree(hc_best, k = k)
  sil <- silhouette(cl, D)

  tibble(
    k = k,
    sil_media = mean(sil[, "sil_width"]),
    sil_min = min(sil[, "sil_width"]),
    sil_max = max(sil[, "sil_width"])
  )
})

sil_results <- bind_rows(sil_results)
sil_results
```

```
# A tibble: 4 x 4
      k sil_media sil_min sil_max
  <dbl>     <dbl>   <dbl>   <dbl>
1     2     0.466 -0.261    0.649
2     3     0.476 -0.0508   0.681
3     4     0.440 -0.411    0.681
4     5     0.413 -0.411    0.674
```

```r
par(mfrow = c(1,4))
for (k in ks) {
  cl <- cutree(hc_best, k = k)
  sil <- silhouette(cl, D)
  plot(
    sil,
    main = paste("Silhueta - complete (k =", k, ")"),
    col = 1:k,
    border = NA
  )
}
```

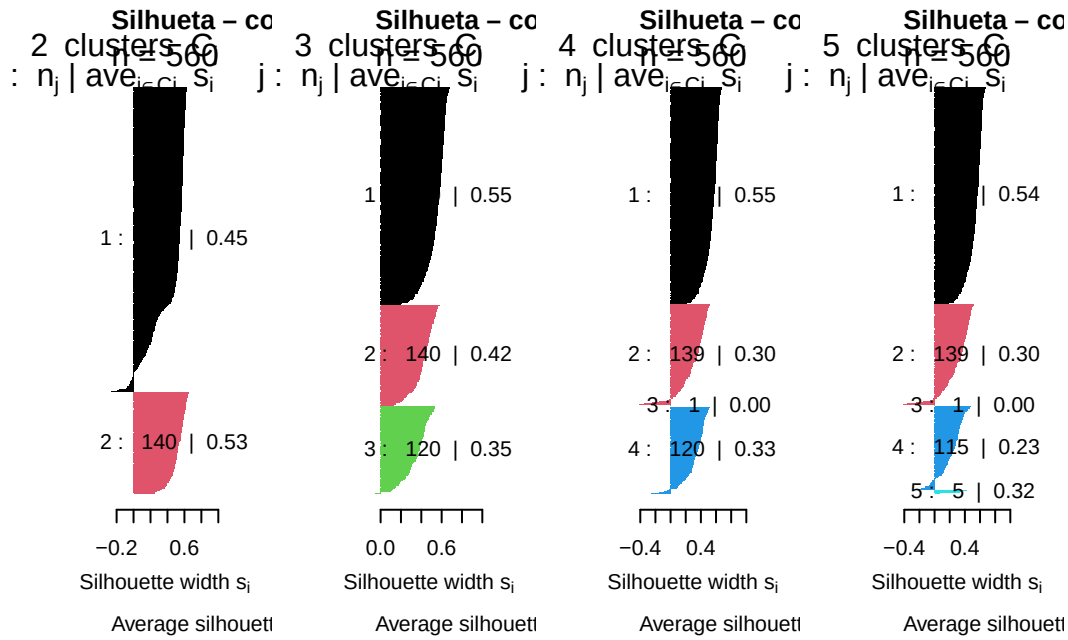


```
par(mfrow = c(1,1))
```

Ao verificar a silhueta para diferentes quantidades de grupos, no caso 2, 4, e 5 grupos, observou-se que o valor da silhueta média é inferior ao proposto (3 grupos), portanto, adotou-se a solução com 3 grupos como partição final dos dados.

Análise descritiva e leitura substantiva

```
# Rótulos hierárquicos com k = 3
cluster_hc_k3 <- cutree(hc_best, k = 3)

dados_hc3 <- dados %>%
  mutate(cluster = factor(cluster_hc_k3))

descr_hc3 <- dados_hc3 %>%
  group_by(cluster) %>%
  summarise(
    n = n(),
    idade_media = mean(idade),
    horas_semana_media = mean(horas_semana),
    media_dias_ativos = mean(dias_ativos),
```

```r
    avaliacoes_medias = mean(avaliacoes),
    tempo_assinatura_medio = mean(tempo_assinatura),
    valor_plano_medio = mean(valor_plano),
    .groups = "drop"
  )

descr_hc3
```

```
# A tibble: 3 x 8
  cluster     n idade_media horas_semana_media media_dias_ativos
  <fct>   <int>       <dbl>              <dbl>             <dbl>
1 1         300        27.4               6.23              2.17
2 2         140        29.2              21.9               5.48
3 3         120        41.0              13.4               4.08
# i 3 more variables: avaliacoes_medias <dbl>, tempo_assinatura_medio <dbl>,
#   valor_plano_medio <dbl>
```

Cluster 1: "Usuários adultos com pouco consumo e planos baratos" (300 usuários, ~54%)

Padrão observado:

- idade média de 27 anos;
- consumo de em média 6.23 horas semanais;
- média de 2.17 dias ativos por semana;
- média de 0.63 avaliações médias;
- tempo médio de assinatura de 9.67 meses;
- valor médio do plano de 35.31 reais.

Leitura substantiva:

- Usuários adultos, com menor consumo de streaming, baixo tempo de assinatura e com planos mais baratos.

Cluster 2: "Usuários adultos fieis com alto consumo e planos mais caros" (140 usuários, ~25%)

Padrão observado:

- idade média de 29 anos;
- consumo de em média 21.91 horas semanais;

- média de 5.48 dias ativos por semana;
- média de 3.51 avaliações médias;
- tempo médio de assinatura de 28.5 meses;
- valor médio do plano de 65.81 reais.

Leitura substantiva:

- Usuários adultos, com alto consumo de streaming, alto tempo de assinatura e planos mais caros.

Cluster 3: "Usuários mais velhos fieis com médio consumo e planos moderados" (120 usuários, ~21%)

Padrão observado:

- idade média de 41 anos;
- consumo de em média 13.44 horas semanais;
- média de 4.1 dias ativos por semana;
- média de 1.96 avaliações médias;
- tempo médio de assinatura de 28.85 meses;
- valor médio do plano de 39,28 reais.

Leitura substantiva:

- Usuários adultos mais velhos, com consumo moderado de streaming, alto tempo de assinatura e planos com preços moderados.

K-médias como método confirmatório

```r
# K-médias depende de inicialização. Use nstart alto para estabilidade.
set.seed(12345)
km <- kmeans(X, centers = 3, nstart = 50)

cluster_km <- km$cluster

table(cluster_km)
```

```
cluster_km
  1   2   3
141 300 119
```

```r
cat("\nInércia total (tot.withinss):", round(km$tot.withinss, 2), "\n")
```

```
Inércia total (tot.withinss): 998.14
```

```r
# Dados com rótulos do K-médias
dados_km <- dados %>%
  mutate(cluster = factor(cluster_km))

# Estatísticas descritivas por cluster
descr_km <- dados_km %>%
  group_by(cluster) %>%
  summarise(
    n = n(),
    idade_media = mean(idade),
    horas_semana_media = mean(horas_semana),
    media_dias_ativos = mean(dias_ativos),
    avaliacoes_medias = mean(avaliacoes),
    tempo_assinatura_medio = mean(tempo_assinatura),
    valor_plano_medio = mean(valor_plano),
    .groups = "drop"
  )

descr_km
```

```
# A tibble: 3 x 8
  cluster     n idade_media horas_semana_media media_dias_ativos
  <fct>   <int>       <dbl>              <dbl>             <dbl>
1 1         141        29.1              21.9               5.47
2 2         300        27.4               6.23              2.17
3 3         119        41.1              13.4               4.07
# i 3 more variables: avaliacoes_medias <dbl>, tempo_assinatura_medio <dbl>,
#   valor_plano_medio <dbl>
```

A partir da aplicação do k-means, obteve-se uma alocação com pouquíssima diferença da alocação feita pelos métodos hierárquicos: Uma observação do grupo de 120 observações foi alocado para o grupo com 140 observações, visto que o grupo com 300 observações manteve-se

sem mudanças nas médias das variáveis. Essa conclusão reforça a robustez dos resultados obtidos.

Conclusões

Diante dos resultados obtidos após a exploração de vários indícios que demonstraram, de forma positiva, a presença de clusters, bem como a quantidade existente de uma estrutura latente de 3 grupos, dividiu-se as observações da seguinte forma:

- usuários adultos com pouco consumo e planos baratos;
- usuários adultos fieis com alto consumo e planos mais caros;
- usuários fieis mais velhos com médio consumo e planos moderados.

Diante disso, evidencia-se que os objetivos do relatório em realizar a análise de agrupamentos foi concluido.

Referências bibliográficas

HAIR, Joseph F. et al. **Análise multivariada de dados**. Bookman editora, 2009.